

Relatorio preliminar para aquisicao de servidor

Plataforma NIAR - justificativa tecnica de configuracao
Data: 10/09/2026

Objetivo

Estou preparando este levantamento para justificar a compra ou disponibilizacao de um servidor em laboratorio para hospedar a plataforma NIAR. A proposta considera o estado atual do projeto, que hoje roda em uma stack containerizada, e tambem uma margem realista para crescimento do monorepo, aumento de usuarios, armazenamento de documentos e entrada gradual de dados.

A recomendacao abaixo nao tem foco em custo de nuvem. O objetivo e definir uma configuracao tecnica coerente para um servidor fisico ou uma VM institucional mantida em laboratorio.

Stack atual considerada

Camada	O que existe hoje	Impacto no servidor
Banco de dados	PostgreSQL 16 em container, com volume persistente.	Precisa de disco confiavel, backup e memoria suficiente para cache.
APIs	admin-api em Node.js e assistente-api em Python/FastAPI.	Consumo moderado de CPU/RAM; cresce com usuarios simultaneos e processamento de documentos.
Frontends	shell, institucional, admin-web e assistente-web servidos como arquivos estaticos.	Baixo consumo em runtime; o maior peso aparece durante build/deploy.
Proxy	Caddy para roteamento HTTP/HTTPS.	Baixo custo computacional; importante para publicacao segura.
Arquivos	Volume de exportacoes do assistente e documentos gerados.	Tende a crescer com uso real; deve ser planejado separadamente do disco do sistema.

Configuracao recomendada

Minha recomendacao para compra e nao trabalhar no limite minimo. A plataforma ainda e leve em uso inicial, mas o servidor tambem deve suportar build do monorepo, banco, logs, backups, arquivos gerados e crescimento do projeto sem exigir troca rapida de maquina.

Item	Minimo viavel	Recomendado para laboratorio	Justificativa
CPU	4 cores / 8 threads	8 cores / 16 threads ou mais	Permite rodar containers e builds sem travar APIs e banco. Build do monorepo e tarefas Python se beneficiam de mais nucleos.
Memoria RAM	16 GB	64 GB, preferencialmente ECC	Postgres usa memoria para cache; Docker/builds podem consumir bastante RAM. 64 GB da margem para crescimento e processamento leve de dados.
Disco principal	500 GB SSD	2 x 1 TB NVMe/SSD em RAID 1	RAID 1 protege contra falha de um disco e melhora confiabilidade. SSD/NVMe reduz gargalo de banco, builds e restauracao.

Item	Minimo viavel	Recomendado para laboratorio	Justificativa
Disco de dados/backup	1 TB adicional	2 TB ou mais para backups, dumps e exportacoes	Dados e backups nao devem disputar espaco com sistema operacional, Docker e banco ativo.
Rede	1 GbE	1 GbE minimo; 10 GbE se houver trafego interno de bases grandes	O uso web comum nao exige muito, mas transferencia de bases e backup podem virar gargalo.
Sistema	Linux x86_64 com Docker	Linux servidor LTS ou Oracle/Rocky Linux, Docker Engine, Docker Compose, Node 22 e pnpm	Mantem compatibilidade com o fluxo de deploy atual e facilita manutencao.

Por que essa configuracao faz sentido

O ponto principal nao e que a aplicacao atual seja pesada. Hoje ela e relativamente simples para uma VM moderna. A justificativa esta na combinacao de servicos e no crescimento esperado: banco de dados, documentos, exportacoes, logs, builds do monorepo e futuramente entrada de bases de pesquisa.

- CPU: quatro cores atendem o MVP, mas oito cores dao folga para build, banco, APIs e tarefas simultaneas sem degradar a experiencia.
- RAM: 16 GB pode funcionar no inicio, mas 64 GB evita gargalo quando Docker, TypeScript/Vite, Python e Postgres estiverem ativos no mesmo servidor.
- Armazenamento: documentos, dumps e exportacoes crescem de forma acumulativa. Por isso recomendo separar disco de sistema/banco e area de backup/dados.
- Confiabilidade: para laboratorio, RAID 1 e backup externo sao mais importantes do que simplesmente comprar mais CPU.
- Escalabilidade: a configuracao recomendada permite evoluir a plataforma sem redesenhar a infraestrutura logo apos o piloto.

GPU e processamento de IA

Eu nao colocaria GPU como requisito para este servidor neste momento, a menos que a decisao seja rodar modelos de IA localmente. Para hospedar a plataforma, APIs, banco e frontends, GPU nao e necessaria. Se no futuro o NIAR quiser inferencia local com modelos grandes, eu trataria isso como outro servidor ou uma expansao especifica, com GPU dedicada, mais RAM e politica propria de seguranca e dados.

Cenarios de evolucao

Cenario	Uso esperado	Configuracao indicada
Piloto/MVP	Poucos usuarios, cadastro, assistente, documentos e acompanhamento administrativo.	4 a 8 cores, 16 a 32 GB RAM, 500 GB SSD.
Producao institucional inicial	Mais usuarios, mais projetos, builds frequentes e maior volume de documentos.	8 cores / 16 threads, 64 GB RAM, 2 x 1 TB SSD/NVMe RAID 1, 2 TB backup.
Entrada de dados de pesquisa	Bases maiores, anexos, processamentos, retencao e auditoria.	16 cores, 128 GB RAM, armazenamento dedicado/NAS ou object storage interno, backup versionado.
IA local	Modelos rodando dentro da infraestrutura do laboratorio.	Servidor separado com GPU dedicada; especificacao depende dos modelos escolhidos.

Boas praticas que eu incluiria no pedido

- Backup automatico do Postgres e dos arquivos gerados, com copia fora do disco principal.
- Monitoramento de CPU, memoria, disco, uso de containers e crescimento do banco.
- Politica de atualizacao do sistema operacional e imagens Docker.
- Separacao entre ambiente de homologacao e producao quando houver uso real por pesquisadores.
- Controle de acesso por SSH, firewall e exposicao publica apenas das portas necessarias.
- Planejamento de retencao de documentos, logs e dumps para evitar crescimento invisivel de disco.

Conclusao

Minha recomendacao para o NIAR e solicitar um servidor de laboratorio com 8 cores / 16 threads, 64 GB de RAM, dois SSDs ou NVMe de 1 TB em RAID 1 e uma area adicional de pelo menos 2 TB para backup e arquivos. Essa configuracao e maior que o minimo necessario para o MVP, mas e adequada para uma plataforma que deve crescer em numero de modulos, usuarios, documentos e dados. Para IA local ou bases grandes, eu trataria como uma segunda etapa de infraestrutura, com dimensionamento proprio.

Fontes internas usadas

- `docker-compose.prod.yml`: define Postgres, APIs, frontends, Caddy e volumes persistentes.
- `infra/vm/README.md` e `infra/vm/cloud-init.yaml`: definem Docker, Node 22, pnpm e padronizacao da VM.
- `README.md` do monorepo: descreve deploy de producao, banco restrito ao host e fluxo com GitHub Actions.